

Universidad de San Andrés

Ciencias del comportamiento



Ciencias de Datos

Docentes:

Maria Noelia Romero

Ignacio Anchorena

Trabajo Práctico 2

Alumnos:

Delfina Borrescio

Catalina Cricco

Candelaria Gilles

Link del repositorio: <https://github.com/ccricco/CC408-Grupo-T2-3>

El presente trabajo práctico tiene como objetivo profundizar en el análisis de la Encuesta Permanente de Hogares (EPH) correspondiente al primer trimestre de los años 2005 y 2025. A partir de la base de datos original, se llevó a cabo un proceso de limpieza y homogeneización de todas las variables con el fin de garantizar la consistencia entre ambos periodos y permitir la comparación de resultados.

Una vez conformada la base final, se procedió a la construcción de nuevas variables derivadas, tales como la edad al cuadrado, los años de educación formal, y el total de horas trabajadas por el jefe de hogar. Posteriormente, se aplicaron técnicas de análisis descriptivo, incluyendo histogramas, distribuciones de kernel y estadísticas de resumen, con el objetivo de explorar las principales características de la población y su relación con la condición de pobreza.

Finalmente se implementaron métodos no supervisados, entre ellos el Análisis de Componentes Principales (PCA) y diferentes técnicas de clustering, que permite identificar patrones latentes en los datos y evaluar si dichas agrupaciones se corresponden con distinciones socioeconómicas relevantes. De esta manera, el trabajo combina herramientas de análisis exploratorio y técnicas multivariadas con el propósito de obtener una caracterización más completa de la estructura social y económica observada en la EPH.

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final

Para esta primera parte del trabajo, utilizamos las 167 variables de la base de datos filtradas por nuestra región Gran Buenos Aires para nuestro análisis de histogramas y kernels.

1- Distribución de la edad

La Figura 1 (Apéndice 1) presenta el histograma de la variable edad para la muestra analizada. Se observa una distribución con alta concentración de individuos en edades tempranas, alcanzando un máximo en la adolescencia y juventud. A partir de los 40 años la frecuencia disminuye progresivamente, reflejando una estructura demográfica en la cual predominan los grupos etarios más jóvenes frente a los adultos mayores.

La Figura 2 (Apéndice 2) muestra la estimación de densidad de kernel diferenciada por condición de pobreza. Los hogares en situación de pobreza exhiben una mayor concentración de individuos en edades jóvenes, con un pico entre los 15 y 20 años. En contraste, los no pobres presentan una distribución más homogénea, con mayor peso relativo en edades medias y adultas. Esta diferencia en la composición etaria sugiere un patrón demográfico asociado a la condición socioeconómica, que será relevante para interpretar los resultados posteriores.

2-Estadísticos descriptivos de la educación

La Tabla 1 (Apéndice 3) resume los estadísticos descriptivos de la variable *educ*, que mide los años de educación formal alcanzados por los individuos. En promedio, la población presenta 10 años y 8 meses de escolaridad, mientras que la mediana se ubica en 12 años, lo que indica que al menos la mitad de los individuos completó la educación secundaria. El desvío estándar, de 10,01, revela una dispersión significativa en los niveles educativos alcanzados, lo que refleja una fuerte heterogeneidad en el acceso y la finalización de la educación. Asimismo, los valores extremos – desde 0 hasta 111 años– sugieren la existencia de registros atípicos o posibles errores de codificación en la base de datos, aspecto que debe tenerse en cuenta en el análisis.

3- Distribución de ingreso total familiar

La Figura 3 (Apéndice 4) presenta el histograma de ingreso total familiar (en pesos de 2025). La distribución está fuertemente sesgada hacia la izquierda, con alta concentración de hogares en los tramos de ingresos bajos. La incorporación de la línea de pobreza permite observar que una proporción significativa de familias se encuentra por debajo de este umbral, lo que confirma la magnitud del problema de la pobreza en la muestra analizada.

La Figura 4 (Apéndice 4) muestra la estimación de densidad de kernel diferenciada por condición de pobreza. Los hogares pobres se concentran de manera marcada en torno a ingresos cercanos a la línea de pobreza, con baja dispersión. Por el contrario, los hogares no pobres exhiben una distribución más amplia, extendiéndose hacia niveles de ingreso considerablemente más elevados. Esta evidencia refleja de manera clara la brecha socioeconómica entre ambos grupos, así como la heterogeneidad interna dentro del segmento de los no pobres.

4- Estadísticos descriptivos de las horas trabajadas

La Tabla 2 (Apéndice 5) presenta los estadísticos descriptivos de la variable *horastrab*, que mide el total de horas trabajadas por el jefe del hogar, sumando ocupación principal y secundaria. En promedio, los individuos reportan aproximadamente 30,8 horas semanales de trabajo, mientras que la mediana se ubica en 25 horas. Esto sugiere que la mayoría trabaja jornadas reducidas, aunque con un grupo que alcanza cargas horarias más altas.

El desvío estándar de 70,9 horas es considerablemente elevado en relación al promedio, lo que indica una gran dispersión en la distribución. Esto se confirma al observar los valores extremos: desde 0 hasta un máximo de 1.083 horas, lo cual revela la presencia de outliers o registros atípicos en la base. La variabilidad encontrada resalta la heterogeneidad en las condiciones laborales de los hogares analizados.

5- Resumen de la base final

La Tabla 3 (Apéndice 6) resume las categorías principales de la base de datos final empleada en el análisis. El total de observaciones asciende a 13.680 de las cuales 3.779 corresponden a hogares pobres y 9.901 a no pobres. No se registraron valores faltantes en la variable de pobreza, lo cual garantiza consistencia en las estimaciones. Asimismo, la base cuenta con 178 variables limpias y homogeneizadas para ambos períodos, lo que asegura la comparabilidad entre 2005 y 2025 y sienta las bases para el análisis de métodos no supervisados de la segunda parte del trabajo.

Parte II - Métodos no supervisados

1- Matriz de correlaciones

A partir de las variables indicadas en la consigna, la Figura 5 (Apéndice 7) presenta la matriz de correlaciones entre las variables seleccionadas para el análisis: edad, edad al cuadrado, años de educación, ingreso total familiar, número de miembros en el hogar y horas trabajadas. El heat map se utiliza como recurso visual para identificar de manera rápida la fuerza y dirección de las relaciones lineales entre las variables.

Los colores indican el signo y magnitud de la correlación: los tonos rojos representan asociaciones positivas (a mayor valor de una variable, mayor valor de la otra), mientras que los tonos azules

reflejan asociaciones negativas (a mayor valor de una variable, menor valor de la otra). La intensidad del color refleja la magnitud: cuanto más oscuro, más fuerte es la correlación.

En los resultados, se observa una alta correlación positiva entre edad y edad al cuadrado (0,96), lo cual era esperable por construcción. En contraste, la edad presenta correlaciones negativas moderadas con el número de miembros en el hogar (-0,43), lo que sugiere que los hogares más jóvenes tienden a tener más integrantes. Por su parte, las demás variables muestran correlaciones bajas, lo que indica una relativa independencia entre los niveles de educación, ingreso, horas trabajables y el resto de los predictores.

2- PCA con ingreso (scores PC1 y PC2)

La Figura 6 (Apéndice 8) presenta el gráfico de dispersión de los individuos en función del primer y segundo componente principal (PC1 y PC2). En conjunto, estos dos componentes explican aproximadamente el 56,7% de la varianza total de los datos (38,9% para PC1 y 17,4% para PC2), lo que permite una reducción sustancial de la dimensionalidad manteniendo más de la mitad de la información original.

La representación gráfica muestra que la mayor parte de las observaciones se concentran en torno al origen, con algunos valores atípicos que se ubican alejados del eje vertical. Esta distribución indica que los primeros dos componentes capturan las principales fuentes de variabilidad, aunque la dispersión relativamente limitada en PC2 sugiere que este componente adicional aporta menos diferenciación que el primero.

En términos analíticos, el PCA resulta útil para identificar patrones latentes en las variables socioeconómicas seleccionadas, reduciendo la complejidad de la información sin perder los rasgos más relevantes. Este resultado sienta las bases para profundizar en la interpretación de los loadings y en la aplicación de técnicas de clustering.

La Figura 7 (Apéndice 9) presenta el biplot de los dos primeros componentes principales, donde se incluyen los vectores (loadings) que indican el peso relativo de cada variable en la construcción de dichos componentes.

Se observa que el primer componente (PC1) está fuertemente influido por las variables *edad* y *edad al cuadrado*, cuyas flechas se orientan en la misma dirección. Esto sugiere que PC1 captura principalmente la variabilidad asociado al ciclo de vida de los individuos. En contraste, el segundo componente (PC2) recibe mayor peso del ingreso total familiar y, en menor medida, del *nivel de educación alcanzado*.

Las variables *número de miembros del hogar* y *horas trabajadas* presentan vectores de menor magnitud, reflejando una contribución más acotada en la explicación de la varianza en los dos primeros componentes. En conjunto, este resultado muestra que la estructura de los datos se organiza principalmente alrededor de la dimensión etaria (PC1) y de la dimensión socioeconómica vinculada al ingreso y la educación (PC2).

La Figura 8a (Apéndice 10) muestra la proporción de varianza explicada individualmente por cada uno de los seis componentes principales. Se observa que el primer componente concentra cerca del 39% de la variabilidad, mientras que el segundo aporta alrededor del 17%. A partir del tercer

componente, la contribución marginal se reduce progresivamente, con valores menores al 16% en adelante.

La Figura 8b (Apéndice 11) presenta la varianza acumulada, donde se aprecia que los dos primeros componentes explican aproximadamente el 56% de la información, mientras que recién con los cinco primeros se alcanza casi el 100%. En conjunto, estos gráficos confirman que los primeros dos componentes concentran la mayor parte de la estructura de los datos, lo que respalda su utilización en los análisis posteriores.

5a- Clustering K-Means

La Figura 9 (Apéndice 12) presenta la segmentación obtenida al aplicar el algoritmo K-Means con $K=2$, considerando como variables la edad y el ingreso total familiar (ITF). Los centroides, representados con estrellas negras, marcan los valores promedio de cada grupo. El gráfico evidencia que la separación entre clusters está determinada principalmente por el nivel de ingreso, aunque existe superposición entre ambos conjuntos de datos.

La Tabla 4 (Apéndice 13) complementa este análisis al mostrar los valores promedio de edad e ingreso en cada cluster. Mientras que la edad promedio resulta muy similar en ambos grupos (35-36 años), las diferencias en el ingreso medio son significativas: el cluster 0 presenta un ingreso promedio superior a los 10 millones de pesos, en contraste con los 2 millones del cluster 1.

En conjunto, los resultados indican que con $k=2$ el algoritmo logra diferenciar hogares de ingresos relativamente altos de aquellos con ingresos más bajos. Sin embargo, la clasificación no coincide de forma precisa con la condición de pobreza medida por la línea de pobreza, por lo que no resulta suficiente para discriminar de manera robusta entre hogares pobres y no pobres.

La Figura 10 (Apéndice 14) muestra la segmentación obtenida al aplicar el algoritmo K-Means con cuatro clusters, utilizando como variables la edad y el ingreso total familiar (ITF). Los centroides de cada grupo se representan con estrellas negras. Los colores del gráfico (azul, naranja, verde y rojo) identifican a cada cluster, permitiendo visualizar cómo se agrupan los hogares en función de las variables analizadas.

Por su parte, la Tabla 5 (Apéndice 15) complementa el análisis al mostrar los promedios de edad e ingreso en cada cluster. El análisis revela que la edad promedio se mantiene prácticamente constante en torno a los 35 años en todos los clusters, lo que confirma que la variable etaria no es un criterio diferenciador en la segmentación. En cambio, los grupos se distinguen casi exclusivamente por los niveles de ingreso: el cluster 1 concentra la mayoría de los hogares con ingresos bajos, el cluster 0 agrupa hogares de ingresos medios, el cluster 2 representa un subconjunto reducido con ingresos altos, mientras que el cluster 3 reúne apenas cuatro observaciones con ingresos extremadamente elevados, que constituyen valores atípicos.

En conjunto, el uso de $k=4$ permite identificar una estructura más detallada de los estratos de ingreso que con $k=2$, aunque la presencia de clusters muy pequeños limita la estabilidad e interpretación de algunos grupos.

La Figura 11 (Apéndice 16) presenta los resultados del algoritmo K-Means con $k=10$. Como en los casos anteriores cada color representa un cluster distinto, mientras que las estrellas negras indican los centroides. Se observa que el algoritmo genera una segmentación mucho más detallada que en los

casos anteriores ($k=2$ y $k=4$), dividiendo a la población en múltiples grupos según los niveles de ingreso. Sin embargo, varios clusters concentran pocas observaciones y corresponden principalmente a valores atípicos con ingresos extremadamente elevados, lo que limita la estabilidad de la clasificación.

La Tabla 6 (Apéndice 17) resume los valores promedio de edad e ingreso en cada cluster. Si bien la edad promedio se mantiene relativamente estable en torno a los 35 años en casi todos los grupos, las diferencias en el ingreso medio son marcadas. El cluster 0 concentra la mayor cantidad de observaciones con ingresos bajos (≈ 724.000 pesos), mientras que clusters como el 1, 2 y 6 corresponden a subconjuntos reducidos de hogares con ingresos excepcionalmente altos, superiores a los 40 millones de pesos.

En conjunto, el uso de $k=10$ permite una segmentación más granular que refleja distintos estratos de ingreso. No obstante, la presencia de clusters muy pequeños, integrados casi exclusivamente por observaciones atípicas, reduce la robustez de la clasificación. Por lo tanto, este nivel de participación puede ser útil para detectar outliers, pero no necesariamente para describir grupos socioeconómicos representativos de la población.

5b- Método de codo

La Figura 12 (Apéndice 18) muestra la evolución de la inercia (WCSS, *within-cluster sum of squares*) en función del número de clusters (k). Como es habitual, a medida que aumenta el valor de k la inercia disminuye, dado que los grupos se vuelven más pequeños y homogéneos. Sin embargo, el descenso no es lineal, la identificación “codo” en la curva permite aproximar el número óptimo de clusters.

En este caso, el punto de inflexión más evidente se encuentra en torno a $k=3$ o $k=4$, donde el agregado de más clusters reduce la inercia en menor medida. Esto sugiere que, para la base analizada, un número entre tres y cuatro clusters ofrece un balance adecuado entre simplicidad y capacidad de diferenciación.

En términos interpretativos, esta cantidad de grupos resulta útil para segmentar la población en distintos estratos socioeconómicos, más allá de la distinción binaria entre pobres y no pobres. No obstante, la presencia de outliers con ingresos extremadamente altos puede sesgar la formación de algunos clusters, lo cual debe ser considerado al analizar los resultados.

6- Clustering jerárquico

La Figura 13 (Apéndice 19) presenta el dendrograma obtenido a partir del análisis de clustering jerárquico. Este gráfico permite visualizar cómo se van agrupando progresivamente las observaciones en función de su similitud, medida a través de la distancia entre individuos o clusters.

En el dendrograma, las ramas más cercanas al eje horizontal corresponden a uniones entre observaciones muy similares, mientras que las uniones más altas representan la fusión de grupos más heterogéneos. La altura de cada bifurcación indica la distancia entre los clusters que se combinan.


En este caso, se observa que los individuos tienden a organizarse inicialmente en pequeños grupos muy homogéneos, que luego se fusionan en conglomerados de mayor tamaño a medida que aumenta la distancia considerada. Este tipo de análisis es útil para identificar estructuras jerárquicas en los datos y decidir un número de clusters adecuado, ya que permite establecer un punto de corte en el dendrograma según el nivel de detalle deseado.

El análisis descriptivo muestra una población predominante joven, con alta heterogeneidad en educación y condiciones laborales. El ingreso total familiar presenta una distribución muy desigual y una proporción relevante de hogares por debajo de la línea de pobreza. El PCA indica que la variabilidad se organiza principalmente en torno a una dimensión etaria (PC1) y una socioeconómica vinculada a ingreso y educación (PC2). Los ejercicios de clustering se segmentan sobre todo por niveles de ingreso; k entre 3 y 4 equilibra simplicidad y diferenciación, aunque la presencia de outliers limita la estabilidad de algunos grupos. En conjunto, la evidencia subraya la persistencia de brechas socioeconómicas y la utilidad de combinar herramientas descriptivas y no supervisadas para caracterizar la población.

Apéndices:


Apéndice 1:

Figura 1. *Histograma de la variable edad*



Apéndice 2:

Figura 2. *Distribución de densidad kernel según condición de pobreza*




Apéndice 3:

Tabla 1
Estadísticos descriptivos de la variable educación (años)

Estadístico	Valor
Count	9.498
Promedio	10,83
Desvío estándar	10,01
Mínimo	0,00
Mediana (p50)	12,00
Máximo	111,00


Apéndice 4:

Figura 3. *Histograma del ingreso total familiar (pesos 2025)*



Apéndice 5:

Figura 4. *Distribución de densidad kernel del ingreso total familiar según condición de pobreza*



Apéndice 6:

Tabla 2

Estadísticos descriptivos de las horas trabajadas por el jefe del hogar

Estadístico	Valor
Count	4.567
Promedio	30,8
Desvío estándar	70,9
Mínimo	0
Mediana (p50)	25,0
Máximo	1.083

Apéndice 7:


Tabla 3

Resumen de la base final por período (2005-2025)

Variable	2005	2025	Total
Cantidad de observaciones	9.371	4.309	13.680
Observaciones con NA en <i>pobreza</i>	0	0	0
Cantidad de pobres	2.438	1.341	3.779
Cantidad de no pobres	6.933	2.968	9.901
Cantidad de variables limpias y homogeneizadas	178	178	178


Apéndice 8:

Figura 5. Matriz de correlaciones entre variables seleccionadas




Apéndice 9:

Figura 6. Dispersión de individuos en los dos primeros componentes principales (PC1 y PC2)




Apéndice 10:

Figura 7. Biplot de ponderadores de las variables en los dos primeros componentes principales




Apéndice 11:

Figura 8a. Varianza explicada individual por componente principal




Apéndice 12:

Figura 8b. *Varianza acumulada de los componentes principales*



Apéndice 13:

Figura 9. *Clustering K-Means con $k=2$ (edad vs. ingreso total familiar)*



Apéndice 14:


Tabla 4

Resumen de clusters obtenidos con K-Means (k=2) (pesos 2025)

Cluster	n	Edad promedio	Ingreso promedio (pesos 2025)
0	688	36,0	10.759.513
1	12.858	35,2	2.002.208

Apéndice 15:

Figura 10. *Clustering K-Means con k=4 (edad vs. ingreso total familiar)*



Apéndice 16:


Tabla 5

Resumen de clusters obtenidos con K-Means ($k=4$)

Cluster	n	Edad promedio	Ingreso promedio (pesos 2025)
0	2.970	35,2	4.708.366
1	10.298	35,2	1.444.698
2	274	35,0	14.287.742
3	4	30,8	92.687.682

Apéndice 17:

Figura 11. *Clustering K-Means con $k=10$ (edad vs. ingreso total familiar)*



Apéndice 18:


Tabla 6

Resumen de clusters obtenidos con K-Means ($k=10$) (pesos 2025)

Cluster	n	Edad promedio	Ingreso promedio (pesos 2025)
0	4.401	36,3	724.498
1	829	35,3	5.799.195
2	4	30,8	92.687.682
3	65	32,1	21.134.288
4	2.472	34,3	2.701.422
5	310	35,6	8.878.698
6	4	34,8	40.957.093
7	3.806	34,4	1.636.841
8	113	37,7	12.692.031
9	1.542	35,4	3.987.192

Apéndice 19:

Figura 12. *Método del codo para determinar el número óptimo de clusters (K-Means)*



Apéndice 20:

Figura 13. *Dendrograma del clustering jerárquico*

