

# Universidad de San Andrés

## Ciencias del comportamiento



## Ciencias de Datos

Docentes:

Maria Noelia Romero

Ignacio Anchorena

### Trabajo Práctico 3

Alumnos:

Delfina Borrescio

Catalina Cricco

Candelaria Gilles

Link del repositorio: <https://github.com/ccricco/CC408-Grupo-T2-3>

### ***A. Enfoque de validación***

Para estimar los determinantes de la pobreza se incluyeron variables vinculadas a la educación, el mercado laboral, el sexo, la inactividad y la localización (CH06, PP3E\_TOT, mujer, en\_pareja, tiene\_cobertura, niveles educativos, tipos de inactividad y GBA). Se analizaron dos bases: 2005 (6.559 casos) y 2025 (3.016 casos), eliminando valores faltantes y variables redundantes. Tras la depuración, quedaron 17 variables en 2005 y 12 en 2025, ya que varias dummies recientes eran constantes o incompletas.

En 2005, la pobreza estuvo determinada por factores estructurales: educación, empleo y formalidad. La educación secundaria y superior reducen fuertemente la probabilidad de pobreza, mientras que la edad y las horas trabajadas muestran efectos protectores. La cobertura médica actúa como indicador de empleo formal, y la inactividad —especialmente entre amas de casa— incrementa el riesgo. Residir en GBA se asocia con mayor pobreza relativa.

En 2025, los patrones cambian parcialmente. La educación mantiene su efecto negativo, aunque con menor magnitud, y emergen con más fuerza factores sociodemográficos: el sexo (mayor vulnerabilidad femenina) y la región (mayor desigualdad metropolitana). La cobertura sigue siendo un factor protector, pero la inactividad pierde peso por la mayor participación laboral y las políticas sociales. En síntesis, entre 2005 y 2025 se reduce el impacto relativo de la educación y crecen los factores demográficos, aunque la formalidad y el capital humano continúan siendo determinantes centrales.

### ***B. Modelo de Regresión Logística***

#### **Ejercicio 3: Resultados del modelo 2005 (Anexo 3)**

La regresión logística estimada para el año 2005 se basó en 6.457 observaciones y 17 variables explicativas, sin problemas de singularidad ni colinealidad. El modelo presenta una buena consistencia teórica y empírica: los signos y magnitudes de los coeficientes se alinean con lo esperado según la literatura sobre determinantes de la pobreza. Entre las variables más relevantes, se observa que tener cobertura médica presenta un coeficiente negativo elevado (-1.55) y un odds ratio de 0.21, lo que indica que las personas con cobertura tienen una probabilidad sustancialmente menor de ser pobres. La educación también aparece como un determinante fundamental: quienes alcanzan nivel secundario (-0.68, OR=0.50) o superior (-1.08, OR=0.33) reducen significativamente sus chances de pobreza respecto al grupo de referencia (sin educación). En contraste, el analfabetismo (0.40, OR=1.49) y la inactividad (0.42, OR=1.53) aumentan la probabilidad de pobreza, reflejando la importancia de la participación laboral y el capital humano. La variable edad (CH06) muestra un pequeño coeficiente negativo (-0.014, OR=0.98), coherente con la idea de que a mayor edad, la estabilidad laboral o los ingresos previsionales reducen el riesgo de pobreza. Finalmente, residir en el Gran Buenos Aires (GBA) tiene un efecto positivo considerable (0.85, OR=2.35), lo que sugiere que en 2005 la pobreza relativa era mayor en áreas metropolitanas respecto al interior del país. El conjunto

de resultados confirma que en 2005 los factores estructurales —educación, empleo formal y localización geográfica— son los principales predictores del riesgo de pobreza (Anexo 3).

El modelo correspondiente a 2025 (Anexo 4) incluye 1.327 observaciones y 12 variables, tras la depuración de valores faltantes y constantes. En general, los resultados mantienen la coherencia con 2005, aunque se observan variaciones en la magnitud y dirección de algunos efectos, especialmente en las variables sociodemográficas.

La cobertura médica continúa siendo un factor protector importante (coef. -2.00, OR=0.13), lo que reafirma la relevancia del empleo formal como vía de reducción de pobreza. La educación secundaria (-0.31, OR=0.73) y superior (-1.21, OR=0.29) siguen mostrando un efecto negativo, aunque más moderado que en 2005, lo que sugiere una mejora general del nivel educativo en la población y una menor desigualdad educativa. A diferencia del modelo anterior, el sexo (mujer) aparece con un efecto positivo leve (0.24, OR=1.27), indicando que las mujeres presentan una probabilidad algo mayor de pobreza en comparación con los varones. Este cambio podría deberse a la persistencia de brechas salariales, a la sobre-representación femenina en empleos informales o a la carga de tareas no remuneradas. En cuanto a la localización, el efecto de vivir en el Gran Buenos Aires (GBA) se mantiene positivo (coef. 0.53, OR=1.71), evidenciando una profundización de la desigualdad metropolitana en 2025. Finalmente, el analfabetismo (1.34, OR=3.79) continúa siendo uno de los predictores más fuertes de pobreza, aunque su incidencia absoluta puede haber disminuido por el avance educativo general. En conclusión, el modelo de 2025 revela una mayor influencia de factores demográficos (género y región) y una leve disminución del peso de la educación, manteniéndose estables los determinantes estructurales de capital humano, empleo y formalidad (Anexo 4).

#### Ejercicio 4:

El gráfico (Anexo 5) muestra la probabilidad estimada de ser pobre en función de la edad, comparando los años 2005 y 2025. En ambos casos se observa una relación negativa: a medida que aumenta la edad, la probabilidad de pobreza disminuye. En 2005, la curva parte de niveles más altos de pobreza entre los jóvenes y desciende más pronunciadamente con la edad, reflejando que la estabilidad laboral y la cobertura previsional protegen a los adultos mayores. En 2025, la pendiente es más suave y las probabilidades iniciales son menores, lo que sugiere una mejoría general en las condiciones económicas y una reducción de la pobreza juvenil, aunque el patrón descendente se mantiene. En general, la visualización confirma que la edad sigue actuando como un factor protector, pero con menor impacto en 2025, posiblemente por la expansión de la educación y la formalización laboral en los grupos más jóvenes.

### ***C. Método de Vecinos Cercanos (KNN)***

#### Ejercicio 5:

En el modelo de K-Vecinos Cercanos (KNN) se clasificaron las observaciones como “pobre” o “no pobre” utilizando valores de  $K=1,5,10$  sobre la matriz de entrenamiento estandarizada (Anexo 6). En 2005, la precisión del modelo aumentó de 0.734 con  $K=1$  a 0.776 con  $K=5$  y 0.783 con  $K=10$ , mostrando que al incrementar  $K$  el modelo gana estabilidad y reduce los falsos positivos, aunque incrementa levemente los falsos negativos. En 2025 se observa un patrón similar: la precisión crece de 0.710 a 0.777, confirmando que un mayor  $K$  suaviza la clasificación y mejora el desempeño general. Este comportamiento refleja el trade-off entre sesgo y varianza: con valores bajos de  $K$ , el modelo tiene baja sesgo pero alta varianza, adaptándose demasiado al ruido; con valores altos, aumenta el sesgo pero disminuye la varianza, generando predicciones más estables. En este caso,  $K=10$  ofrece el mejor equilibrio entre precisión y estabilidad en ambos años (Anexo 6).

#### Ejercicio 6:

Para visualizar el comportamiento de modelo KNN, se graficaron las fronteras de decisión de clasificación entre “pobre” y “no pobre” según dos variables numéricas clave: edad (CH06) y horas trabajadas (PP3E\_TOT), utilizando valores de  $K = 1, 5$  y  $10$  para los años 2005 y 2025 (véase Figura 2 en el Anexo 7). En las visualizaciones se observa que, para  $K = 1$ , las fronteras son irregulares y fragmentadas, reflejando un sobreajuste del modelo a los datos individuales y una alta varianza. A medida que  $K$  aumenta a 5 y 10, las fronteras se vuelven más suaves y homogéneas, indicando una menor sensibilidad al ruido y una mejor capacidad de generalización. En el caso de 2005, las zonas asociadas a la pobreza se concentran en individuos de menor edad y menor cantidad de horas trabajadas, lo que sugiere que la inserción laboral y la experiencia actúan como factores protectores frente a la pobreza. En 2025, la separación entre clases se vuelve menos marcada, lo que podría reflejar una reducción de las brechas estructurales y una mayor homogeneidad en las condiciones laborales y educativas. En conjunto, los resultados visuales complementan los hallazgos del ejercicio anterior: el incremento del parámetro  $K$  reduce la varianza del modelo, mejora la estabilidad de las predicciones y mantiene el equilibrio entre precisión y generalización.

#### Ejercicio 7:

Con el objetivo de determinar el número óptimo de vecinos, se aplicó una validación cruzada de 5 pliegues (5-Fold-Cross-Validation) sobre la base *respondieron\_2025*, evaluando el desempeño del modelo KNN para diferentes valores de  $K$  (véase Figura 3 en el Anexo 8). El gráfico muestra cómo la precisión promedio del modelo (accuracy) aumenta de manera pronunciada entre  $K = 1$  y  $K = 5$ , para luego estabilizarse gradualmente. A partir de  $K \approx 10$ , la curva alcanza una meseta, indicando que el incremento en  $K$  deja de aportar mejoras significativas en la capacidad predictiva. El valor de  $K=10$  se seleccionó como el óptimo, ya que ofrece el mejor equilibrio entre precisión y estabilidad, minimizando la varianza sin introducir un sesgo excesivo. Este resultado es consistente con lo

observado en los ejercicios anteriores, donde el aumento de K también mejoró la consistencia del modelo y redujo los errores de clasificación aleatorios.

#### ***D. Desempeño de modelos, elección y predicción afuera de la muestra***

##### Ejercicio 8:

Para comparar el desempeño de los modelos de clasificación, se evaluaron las predicciones del Logit 2025 y del KNN-CV 2025 sobre la base de testeo, considerando métricas de precisión global (accuracy), sensibilidad (recall) y el área bajo la curva ROC (AUC). Las matrices de confusión correspondientes se presentan en las Figuras 4 (Anexo 9) y 5 (Anexo 10). El modelo Logit 2025 alcanza una accuracy de 0.817 y un AUC de 0.783, mostrando una buena capacidad de discriminación general. Sin embargo, el recall de 0.385 indica que el modelo tiende a clasificar con menor sensibilidad a las personas efectivamente pobres, priorizando la correcta identificación de los no pobres (bajo riesgo de falsos positivos). Por su parte, el modelo KNN-CV 2025 obtiene una accuracy muy similar (0.819), pero un AUC menor (0.733) y un recall más bajo (0.325), lo que sugiere un desempeño ligeramente inferior al Logit en la detección de verdaderos positivos. Además, la matriz de confusión evidencia que el KNN produce un número mayor de falsos negativos, es decir, personas pobres clasificadas como no pobres. En conjunto, ambos modelos presentan un rendimiento comparable en términos de precisión general, aunque el Logit 2025 ofrece mayor capacidad discriminatoria y sensibilidad, resultando más adecuado para el objetivo de identificar grupos vulnerables. Este hallazgo se retoma en el ejercicio siguiente, al discutir cuál modelo es más apropiado para orientar políticas de asistencia focalizada. Además la Figura 6 (Anexo 11) muestra las curvas ROC correspondientes a ambos modelos, permitiendo evaluar su capacidad de discriminación entre personas pobres y no pobres. En el gráfico se observa que la curva del modelo Logit (AUC = 0.783) se mantiene por encima de la del KNN-CV (AUC = 0.733) a lo largo de toda la distribución de sensibilidad y especificidad, lo que indica un mejor desempeño global. La mayor área bajo la curva del Logit refleja una probabilidad más alta de clasificar correctamente a un individuo pobre respecto de uno no pobre, evidenciando su superioridad en términos de precisión y balance entre verdaderos positivos y negativos. En contraste, el modelo KNN-CV muestra una curva más cercana a la diagonal, lo que sugiere menor capacidad predictiva y una mayor tendencia a errores de clasificación. En términos generales, los resultados del ejercicio confirman que el modelo Logit presenta mayor poder de discriminación y estabilidad, por lo que se posiciona como el modelo más adecuado para identificar correctamente a las personas en situación de pobreza.

##### Ejercicio 10:

Finalmente, se utilizó el modelo Logit 2025, identificado como el más adecuado, para predecir la probabilidad de pobreza en la base *norespondieron\_2025*. Las probabilidades estimadas se ubicaron entre 0.20 y 0.48, con una media de 0.40, lo que refleja un rango acotado y coherente con los valores

observados en la base de entrenamiento. Aplicando un umbral de 0.4, el modelo clasificó como pobres al 50% de las personas de esta base. Este resultado sugiere una distribución equilibrada de las predicciones y una buena capacidad del modelo para identificar casos de riesgo medio de pobreza. En síntesis, el modelo Logit logra extender la clasificación de pobreza a los individuos sin información de ingreso, proporcionando una herramienta confiable para estimar vulnerabilidad social y orientar decisiones de política pública basadas en evidencia. En conclusión, los resultados obtenidos permiten concluir que la pobreza en Argentina continúa determinada por factores estructurales vinculados a la educación, la inserción laboral y la formalidad. Sin embargo, en 2025 emergen con mayor peso los factores demográficos, como el género y la localización geográfica.

### **Anexos:**

#### **Anexo 1:**

Tabla 1. *Diferencia de medias entre base de entrenamiento y base de testeo (año 2005).*

| Variable            | Media train | Media test | Dif. media | p value | Significativa 5 % |
|---------------------|-------------|------------|------------|---------|-------------------|
| CH06                | 348.491     | 330.915    | 2.327      | 2.327   | FALSE             |
| PP3E_TOT            | 191.910     | 186.066    | 3.288      | 3.288   | FALSE             |
| tiene_cobertura     | 8.518       | 8.237      | 0.281      | 2.843   | FALSE             |
| mujer               | 5.518       | 5.237      | 0.281      | 4.335   | FALSE             |
| inac_jubilado       | 0.796       | 0.862      | -0.066     | 7.454   | FALSE             |
| GBA                 | 7.344       | 7.634      | -0.291     | 4.454   | FALSE             |
| CABA                | 2.396       | 2.062      | 0.334      | 4.154   | FALSE             |
| edu_superior        | 1.623       | 1.770      | -0.148     | 5.698   | FALSE             |
| edu_secundario      | 5.218       | 5.078      | 0.140      | 6.913   | FALSE             |
| analfabeto          | 0.176       | 0.115      | 0.060      | 5.478   | FALSE             |
| inac_estudiante     | 1.115       | 1.154      | -0.039     | 9.048   | FALSE             |
| inac_otros          | 0.705       | 0.770      | -0.065     | 7.073   | FALSE             |
| paren_otro          | 1.473       | 1.489      | -0.016     | 9.576   | FALSE             |
| en_pareja           | 4.173       | 4.189      | -0.016     | 9.748   | FALSE             |
| inactivo            | 1.459       | 1.320      | 0.139      | 6.681   | FALSE             |
| inac_amasca         | 0.696       | 0.662      | 0.034      | 8.583   | FALSE             |
| desocupado          | 0.650       | 0.743      | -0.093     | 5.958   | FALSE             |
| paren_conyugue_hijo | 8.073       | 7.953      | 0.120      | 7.077   | FALSE             |
| intercepto          | 1.200       | 1.200      | 0.000      | NaN     | FALSE             |

**Anexo 2:**Tabla 2. *Diferencia de medias entre la base de entrenamiento y la base de testeo (año 2025).*

| Variable           | Media_train | Media_test | Dif_media | p_value | significativa_5% |
|--------------------|-------------|------------|-----------|---------|------------------|
| PP3E_TOT           | 360.445     | 343.188    | 1.7257    | 4.677   | FALSE            |
| CH06               | 369.768     | 374.323    | -4.555    | 5.477   | FALSE            |
| en_pareja          | 3.883       | 4.130      | -247      | 1.299   | FALSE            |
| inactivo           | 5.196       | 4.957      | 238       | 5.238   | FALSE            |
| inac_estudiante    | 2.357       | 2.127      | 231       | 939     | FALSE            |
| CABA               | 2.092       | 2.305      | -213      | 3.213   | FALSE            |
| GBA                | 7.908       | 7.695      | 213       | 1.873   | FALSE            |
| tiene_cobertura    | 7.049       | 7.254      | -205      | 1.693   | FALSE            |
| edu_superior       | 2.478       | 2.127      | 351       | 1.783   | FALSE            |
| paren_conyuge_hijo | 5.485       | 5.309      | 176       | 4.894   | FALSE            |
| edu_secundario     | 5.166       | 5.054      | 113       | 6.941   | FALSE            |
| paren_otro         | 700         | 845        | -145      | 2.383   | FALSE            |
| analfabeto         | 61          | 54         | 6         | 8.858   | FALSE            |
| mujer              | 5.249       | 5.025      | 224       | 2.944   | FALSE            |
| desocupado         | 450         | 433        | 16        | 9.269   | FALSE            |
| inac_jubilado      | 784         | 662        | 121       | 4.605   | FALSE            |
| inac_amasca        | 948         | 911        | 37        | 9.152   | FALSE            |
| inac_otros         | 703         | 844        | -142      | 4.964   | FALSE            |

**Anexo 3:**Tabla 3. *Resultados del modelo Logit para el año 2005.*

| Variable        | Coefficiente | Error estándar | Odds Ratio |
|-----------------|--------------|----------------|------------|
| CH06            | -0.0114      | 0.0027         | 0.9817     |
| PP3E_TOT        | -0.0010      | 0.0005         | 0.9990     |
| mujer           | 0.0314       | 0.0901         | 1.0319     |
| en_pareja       | 0.0253       | 0.0933         | 1.0256     |
| tiene_cobertura | -0.1553      | 0.0751         | 0.8561     |
| edu_secundario  | -0.6800      | 0.0024         | 0.5066     |
| edu_superior    | -0.3780      | 0.0934         | 0.6854     |
| desocupado      | 0.6276       | 0.1256         | 1.8735     |
| inactivo        | 0.1478       | NaN            | 1.1593     |
| inac_jubilado   | 0.3150       | NaN            | 1.3697     |

|                 |         |        |        |
|-----------------|---------|--------|--------|
| inac_estudiante | 0.4170  | NaN    | 1.5177 |
| inac_amasca     | 0.4439  | NaN    | 1.5589 |
| inac_otros      | 0.3042  | NaN    | 1.3554 |
| analfabeto      | 0.2765  | NaN    | 1.3184 |
| paren_otro      | -0.0478 | 0.1327 | 0.9533 |
| GBA             | 0.0483  | 0.0869 | 1.0495 |
| intercepto      | -0.5746 | 0.1574 | 0.5629 |


#### Anexo 4:

Tabla 4. *Resultados del modelo Logit para el año 2025.*

| Variable           | Coefficiente | Error estándar | Odds Ratio |
|--------------------|--------------|----------------|------------|
| CH06               | -92          | 67             | 9.908      |
| PP3E_TOT           | -8           | 13             | 9.992      |
| mujer              | 2.412        | 1.614          | 1.2728     |
| en_pareja          | 5.793        | 1.688          | 1.7847     |
| tiene_cobertura    | -20.004      | 1.713          | 1.354      |
| edu_secundario     | -3.138       | 1.775          | 7.307      |
| edu_superior       | -12.132      | 2.642          | 2.967      |
| analfabeto         | 1.3331       | 7.311          | 3.7937     |
| paren_conyuge_hijo | -4.371       | 1.784          | 6.458      |
| paren_otro         | -8.202       | 4.843          | 4.403      |
| GBA                | 5.399        | 2.217          | 1.7158     |
| intercepto         | 2.859        | 4.048          | 1.3309     |

#### Anexo 5:

Figura 1. *Probabilidad estimada de ser pobre según la edad (años 2005 y 2025).*






**Anexo 6:**Tabla 5. Resultados del modelo *K-Vecinos Cercanos (KNN)* para los años 2005 y 2025.

| Matriz de confusión K = 1 año 2005   Accuracy = 0,734  |          |                |          |
|--------------------------------------------------------|----------|----------------|----------|
|                                                        |          | Valores reales |          |
|                                                        |          | Positivo       | Negativo |
| Valores predichos                                      | Positivo | 358            | 387      |
|                                                        | Negativo | 361            | 1706     |
| Matriz de confusión K = 5 año 2005   Accuracy = 0,776  |          |                |          |
|                                                        |          | Valores reales |          |
|                                                        |          | Positivo       | Negativo |
| Valores predichos                                      | Positivo | 342            | 252      |
|                                                        | Negativo | 377            | 1841     |
| Matriz de confusión K = 10 año 2005   Accuracy = 0,783 |          |                |          |
|                                                        |          | Valores reales |          |
|                                                        |          | Positivo       | Negativo |
| Valores predichos                                      | Positivo | 288            | 178      |
|                                                        | Negativo | 431            | 1915     |
| Matriz de confusión K = 1 año 2025   Accuracy = 0,710  |          |                |          |
|                                                        |          | Valores reales |          |
|                                                        |          | Positivo       | Negativo |
| Valores predichos                                      | Positivo | 208            | 189      |
|                                                        | Negativo | 186            | 710      |
| Matriz de confusión K = 5 año 2025   Accuracy = 0,770  |          |                |          |
|                                                        |          | Valores reales |          |
|                                                        |          | Positivo       | Negativo |
| Valores predichos                                      | Positivo | 205            | 108      |
|                                                        | Negativo | 189            | 791      |
| Matriz de confusión K = 10 año 2025   Accuracy = 0,777 |          |                |          |
|                                                        |          | Valores reales |          |
|                                                        |          | Positivo       | Negativo |

|                   |          | Positivo | Negativo |
|-------------------|----------|----------|----------|
| Valores predichos | Positivo | 190      | 84       |
|                   | Negativo | 204      | 815      |


## Anexo 7:

Figura 2. Clasificación de pobreza según edad y horas trabajadas para distintos valores de K (años 2005 y 2025).




## Anexo 8:

Figura 3. Precisión media del modelo KNN según número de vecinos (validación cruzada 5-Fold, año 2025).




## Anexo 9:

Figura 4. Matriz de confusión del modelo Logit (año 2025).



### Anexo 10:

Figura 5. Matriz de confusión del modelo KNN-CV (año 2025).



### Anexo 11:

Figura 6. Curvas ROC comparativas de los modelos Logit y KNN-CV (año 2025).

