

Universidad de San Andrés

Ciencias del comportamiento



Ciencias de Datos

Docentes:

Maria Noelia Romero

Ignacio Anchorena

Trabajo Práctico 4

Alumnos:

Delfina Borrescio

Catalina Cricco

Candelaria Gilles

Link del repositorio:

<https://github.com/ccricco/CC408-Grupo-T2-3>

El presente trabajo analiza la capacidad predictiva de distintos modelos de clasificación aplicados a la Encuesta Permanente de Hogares (EPH) del año 2025, con el objetivo de identificar hogares en situación de pobreza. A diferencia del TP3, donde el énfasis estuvo puesto en explicar los determinantes estructurales de la pobreza, en este TP4 el enfoque se orienta a comparar métodos predictivos que difieren en complejidad, interpretabilidad y capacidad de generalización.

En particular, se evalúan tres familias de modelos: regresiones logísticas con penalización L1(LASSO) y L2 (Ridge), árboles de decisión podados mediante costo de complejidad (CART) y los modelos ya estimados previamente (Logit sin penalidad y KNN seleccionados por validación cruzada). La comparación se basa en métricas fuera de muestra, considerando desempeño predictivo y la utilidad práctica de cada modelo en un contexto de política pública donde el ministerio de capital humano debe asignar recursos de manera focalizada.

El objetivo general es determinar qué método ofrece el mejor equilibrio entre precisión, interpretabilidad y capacidad de identificar correctamente a los hogares vulnerables, entendiendo las limitaciones y ventajas de cada enfoque.

Métodos

El análisis se realizó utilizando las matrices de entrenamiento y testeo construidas previamente en el TP3 para el año 2025, manteniendo el mismo conjunto de variables sociodemográficas, educativas y laborales. Todas las estimaciones se implementaron en Python utilizando *scikit-learn*.

Para los modelos de regularización se usó una grilla de valores de penalización definida como: $\lambda = 10^{-n}$, donde n toma valores entre -5 y 5. El mejor valor de la penalidad se seleccionó mediante validación cruzada de 5 pliegues. Se ajustaron modelos con penalización L1(LASSO) y L2 (Ridge).

El modelo de árboles de decisión se estimó con el algoritmo CART, seleccionando el parámetro de poda (ccp_alpha) mediante validación cruzada de 10 pliegues. El árbol final corresponde al valor de ccp_alpha que minimizó el error de clasificación promedio.

El desempeño de cada modelo se evaluó en la base de testeo utilizando matriz de confusión, accuracy, error de clasificación (1-accuracy) y área bajo la curva ROC (AUC). Estas métricas permiten comparar la capacidad predictiva y la utilizada de cada modelo para identificar hogares pobres.

A. Modelo de Regresión logística con regularización: Ridge y LASSO

1. Visualización

La Figura 1 (Anexo 1) presenta cómo varían los coeficientes de la regresión logística bajo los métodos LASSO y Ridge, presentados en dos paneles: el izquierdo corresponde a LASSO y el derecho a Ridge. En el eje horizontal se representa la penalización usando valores de “ 10^{-n} ”, de modo que hacia la derecha la regularización es más fuerte.

En el panel de LASSO, se observa que, a medida que aumenta la penalización, varios coeficientes se reducen exactamente a cero. Esto refleja que LASSO no solo achica los coeficientes, sino que también puede eliminar variables por completo, seleccionando únicamente las más relevantes.

En cambio, en el panel de Ridge los coeficientes también disminuyen, pero ninguno llega a cero. Ridge contrae los valores de manera continua, manteniendo todas las variables en el modelo y evitando la eliminación total de predictores.

En conjunto, la figura ilustra la diferencia central entre ambos métodos: LASSO realiza selección de variables al llevar ciertos coeficientes a cero, mientras que Ridge solo los reduce sin excluir predictores.

2. Penalidad óptima por Cross-validation y visualización

La Figura 2 (Anexo 2) muestra los errores de clasificación obtenidos mediante validación cruzada para cada valor de lambda ($10^{\text{elevado a } n}$). En ambos métodos se observa que, para penalizaciones bajas o moderadas, el error medio se mantiene relativamente estable, mientras que penalizaciones muy altas generan un aumento claro del error.

En LASSO (L1), el valor óptimo de lambda fue 10^{-4} ($n=4$), con un error medio de validación del 0.2178. Para penalizaciones mayores, los boxplots muestran un aumento pronunciado del error, lo que indica que el modelo pierde capacidad predictiva cuando la regularización es demasiado fuerte y elimina demasiadas variables.

En Ridge (L2), el lambda óptimo fue 0.0001 ($n=-4$), con un error medio de 0.2182. Al igual que en LASSO, los valores altos de penalización aumentan el error, pero Ridge mantiene trayectorias más estables debido a que no elimina variables, sino que solo reduce su magnitud.

En líneas generales, la validación cruzada muestra que ambos métodos alcanzan su mejor desempeño con niveles de penalización relativamente bajos, y que penalizaciones excesivas deterioran la precisión del modelo.

Además la Figura 3 (Anexo 3) muestra cómo aumenta la proporción de coeficientes iguales a cero cuando se incrementa la penalización en LASSO. Para valores bajos de lambda no se eliminan variables, pero a partir de penalizaciones más altas la proporción crece rápidamente y llega a valores cercanos al 90%. Esto confirma el comportamiento de LASSO como método que realiza selección de variables, reduciendo la complejidad del modelado a medida que la regularización se vuelve más fuerte.

3. Estimación con λ^{cv} y comparación de coeficientes

La Tabla 1 (Anexo 4) muestra los coeficientes estimados sin penalización y con las penalidades L1 y L2 utilizando los valores óptimos de C seleccionados por validación cruzada ($C = 0.1$ para LASSO y $C = 10.000$ para Ridge). La comparación permite observar cómo cada tipo de regularización modifica la magnitud de los coeficientes y la presencia de variables activas en el modelo.

En el caso de LASSO (L1), varios coeficientes se reducen exactamente a cero, como los correspondientes a *inac_estudiante*, *analfabeto*, *paren_otro* y *CABA*. Esto confirma que la penalización L1 realiza selección automática de variables, eliminando aquellas que aportan menos información predictiva. Para las variables que permanecen activas, LASSO también reduce la magnitud de los coeficientes en comparación con el modelo sin penalidad.

Por el contrario, Ridge (L2) mantiene todas las variables en el modelo, pero con una contracción generalizada de los coeficientes. Aunque los valores se reducen respecto al modelo sin penalización, ninguno se vuelve exactamente cero, lo cual es consistente con el comportamiento esperado del método L2.

A partir de estas diferencias, LASSO tiende a producir modelos más simples mediante la eliminación de predictores, mientras que Ridge mantiene todas las variables y solo reduce su magnitud.

B. Árboles de Clasificación (CART)

4. Penalidad óptima (ccp_alpha) y selección del árbol podado

La Figura 4 (Anexo 5) muestra el error de clasificación promedio obtenido mediante validación cruzada de 10 pliegues para distintos valores del parámetro *ccp_alpha*. El gráfico presenta un descenso inicial pronunciado del error a medida que aumenta *ccp_alpha* desde valores cercanos a cero, seguidos por una zona relativamente estable en la que el error se mantiene bajo.

El valor óptimo seleccionado fue *ccp_alpha* = 0.005534, correspondiente al punto con el menor error promedio. Este valor permite podar el árbol eliminando divisiones que no aportan mejora en el desempeño predictivo, evitando tanto el sobreajuste como un árbol excesivamente profundo.

5. Visualización del árbol podado e importancia de predictores

La Figura 5 (Anexo 6) muestra el árbol de decisión podado utilizando el valor óptimo de *ccp_alpha* obtenido por validación cruzada. El árbol resultante es muy sencillo y muestra una única división relevante: la variable *tiene_cobertura*. Las observaciones sin cobertura médica se clasifican mayormente como pobres, mientras que quienes sí poseen cobertura se agrupan principalmente como no pobres. Esta estructura indica que la cobertura actúa como el criterio más informativo para separar las clases en el modelo CART.

La poda eliminó divisiones adicionales que no mejoraba el desempeño, lo que permitió obtener un árbol más estable, fácil de interpretar y consistente con la importancia relativa de las variables observadas en los resultados del modelo.

La Figura 6 (Anexo 7) muestra la importancia de cada predictor dentro del árbol podado. Tal como se observa, la variable *tiene_cobertura* concentra prácticamente toda la importancia del modelo, mientras que el resto de las variables aportan valores cercanos a cero. Este patrón indica que, para el árbol seleccionado, la cobertura médica es el criterio dominante para separar las clases, lo que coincide con la única división presente en el árbol del Panel A.

La ausencia de otros predictores relevantes refleja que, tras la poda, el árbol prioriza la simplicidad y retiene únicamente la variable que aporta mayor reducción de impureza. Este resultado es consistente con el comportamiento observado en los métodos de regularización: las variables con menor aporte predictivo también tienden a ser reducidas o eliminadas en modelos como LASSO.

C. Comparación entre métodos

6. Comparación de desempeño: matrices de confusión, accuracy, error y AUC

La Tabla 2 (Anexo 8) resume las métricas de desempeño fuera de muestra para todos los modelos: Logit sin penalidad, KNN (K óptimo), LASSO, Ridge y el árbol podado. Los resultados muestran que los modelos basados en regresión logística — tanto sin penalización como con Ridge y LASSO — presentan desempeños muy similares, con valores de accuracy cercanos a 0.79–0.80, errores de clasificación alrededor de 0.21 y los mayores AUC del conjunto (entre 0.826 y 0.829). Esto indica una buena capacidad para distinguir entre hogares pobres y no pobres. (véase Tabla 2, Anexo 8)

El modelo KNN es el de menor desempeño, con un AUC de 0.768 y el error más alto, lo cual refleja una menor capacidad de generalización. Por su parte, el árbol podado obtiene valores intermedios, con un AUC de 0.801 y un error levemente mayor que los modelos logísticos, aunque mantiene un rendimiento razonable dadas sus restricciones estructurales.

Las matrices de confusión (Figuras 7.1 a 7.5 en el Anexo 9) reflejan estas diferencias. Los modelos logísticos muestran un balance adecuado entre verdaderos positivos y verdaderos negativos, mientras que KNN presenta más falsos negativos y el árbol podado tiende a clasificar la mayoría de los casos como no pobres, reduciendo la sensibilidad.

7. Comparación global y trade-off entre interpretabilidad y desempeño

Las curvas ROC (Figura 8, Anexo 10) muestran que los tres modelos logísticos — sin penalidad LASSO y Ridge— dominan al resto en casi toda la distribución de tasas de verdaderos y falsos positivos. KNN queda sistemáticamente por debajo, y el árbol podado muestra un desempeño intermedio pero más bajo que los modelos lineales. Esto confirma que, para este problema, las relaciones entre las variables y la pobreza son relativamente estables y bien capturadas por modelos lineales regulares.

En cuanto al trade-off entre interpretabilidad y desempeño, el árbol podado es el más fácil de comunicar, ya que utiliza un único criterio de separación (tener cobertura médica). Sin embargo, esta simplicidad implica una pérdida de precisión respecto de los modelos logísticos. Por el contrario, los modelos con regularización ofrecen el mejor equilibrio: mantienen coeficientes interpretables, ajustan la complejidad del modelo y logran el mejor desempeño global en accuracy y AUC.

Considerando que el ministerio de Capital Humano necesita identificar hogares vulnerables sin aumentar errores de exclusión, el modelo regresión logística con penalización Ridge aparece como la

opción más adecuada. Ofrece el mayor AUC, bajo error de clasificación y una estructura interpretable y estable, sin eliminar predictores relevantes.

Conclusiones

Los resultados muestran que los modelos de regresión logística — tanto sin penalización como con LASSO y Ridge— fueron los que obtuvieron el mejor desempeño, con los mayores valores de AUC y los menores errores de clasificación. Esto indica que, para la EPH 2025, la relación entre variables y la pobreza puede capturarse de manera efectiva con modelos lineales regularizados.


Los métodos no lineales presentaron un rendimiento menor. KNN mostró la peor capacidad predictiva y el árbol podado, aunque muy interpretable, perdió sensibilidad al clasificar la mayoría de los casos como no pobres.

Considerando el objetivo de identificar hogares vulnerables para la asignación de recursos públicos, el modelo de regresión logística con penalización Ridge aparece como la opción más adecuada, ya que combina buen desempeño, estabilidad e interpretabilidad.

Anexos:


Anexo 1:

Figura 1. Trayectorias de coeficientes bajo penalización LASSO (izquierda) y Ridge (derecha).




Anexo 2:

Figura 2. Errores de validación cruzada para distintos valores de lambda en LASSO (izquierda) y Ridge (derecha).



Anexo 3:

Figura 3. Proporción de coeficientes iguales a cero en LASSO para distintos valores de lambda.



Anexo 4:


Tabla 1. Coeficientes del modelo sin penalización, con penalización L1 y con penalización L2.

Variable	Coef_sin_penalidad	Coef_L1	Coef_L2
ANO4	2.775082e-04	0.000125	2.774440e-04
CH06	-1.353338e-02	-0.012221	-1.352018e-02
PP3E_TOT	-7.395148e-04	-0.000727	-7.400206e-04
mujer	1.702522e-01	0.055594	1.704139e-01
en_pareja	3.725725e-01	0.115497	3.720171e-01
tiene_cobertura	-1.884490e+00	-1.839041	-1.885316e+00
edu_secundario	-3.626084e-01	-0.187759	-3.636267e-01
edu_superior	-9.585378e-01	-0.564968	-9.597130e-01

desocupado	1.351832e+00	0.638039	1.351724e+00
inactivo	5.732010e-01	0.546701	5.731514e-01
inac_jubilado	-9.757033e-01	-0.603449	-9.749038e-01
inac_estudiante	3.240042e-01	0.000000	3.233899e-01
inac_amasca	4.383772e-01	0.142062	4.385325e-01
inac_otros	7.865230e-01	0.094348	7.861328e-01
analfabeto	6.720660e-02	0.000000	6.890800e-02
paren_conyuge_hijo	-4.766784e-01	-0.043843	-4.758336e-01
paren_otro	-5.802795e-01	0.000000	-5.801602e-01
GBA	3.049828e-01	0.496594	3.054861e-01
CABA	-3.049287e-01	0.000000	-3.054859e-01
intercepto	1.370411e-07	0.000000	1.370094e-07

Anexo 5:


Figura 4. Error de validación cruzada en función de ccp_alpha para el modelo CART.



Anexo 6:


Figura 5. Árbol de decisión podado mediante costo de complejidad (Panel A).

Panel A: Árbol de Decisión Podado (CART)



Anexo 7:

Figura 6. Importancia de predictores en el árbol de decisión podado (Panel B).



Anexo 8:

Tabla 2. Métricas de desempeño fuera de muestra para todos los modelos

Modelo	Accuracy	1-Error	AUC
Logit_sin_penalidad	0.791183	0.208817	0.829070

KNN	0.758701	0.241299	0.768547
LASSO	0.790410	0.209590	0.826580
Ridge	0.791183	0.208817	0.829092
Árbol_podado	0.784996	0.215004	0.801960

Anexo 9:

Figura 7.1. Matriz de confusión – Logit sin penalización.

	Predicho 0	Predicho 1
Real 0	807	92
Real 1	178	216

Figura 7.2. Matriz de confusión — KNN (K óptimo).

	Predicho 0	Predicho 1
Real 0	834	65
Real 1	247	147

Figura 7.3. Matriz de confusión — LASSO (L1).

	Predicho 0	Predicho 1
Real 0	795	104
Real 1	167	227

Figura 7.4. Matriz de confusión — Ridge (L2).

	Predicho 0	Predicho 1
Real 0	807	92
Real 1	178	216

Figura 7.5. Matriz de confusión — Árbol podado.

	Predicho 0	Predicho 1
Real 0	809	90
Real 1	188	206

Anexo 10:

Figura 8. Curvas ROC comparativas de todos los modelos.

